DOCUMENTAÇÃO TÉCNICA E ARQUITETURAL DO PROJETO

Pipeline de ETL, Metodologia Estatística, LGPD, Debugging e Insights de Negócio.

1. Visão Geral e Contextualização do Projeto

Este documento registra a arquitetura completa, decisões metodológicas, conformidade regulatória e resolução de erros referentes ao projeto de Pesquisa Estatística Descritiva dos tempos da corrida de 5km. O objetivo central foi estruturar um pipeline de dados reprodutível, modular e aderente aos padrões corporativos.

2. Coleta, Origem e Tratamento de Dados (ETL)

2.1 Princípio da Imutabilidade dos Dados Brutos

Os dados originais foram mantidos na pasta dados/raw/ sem qualquer intervenção manual. Todo o processo de saneamento, conversão de tipos e filtragem é realizado programaticamente pelos scripts na pasta src/.

2.2 Governança de Dados e Conformidade com a LGPD (Lei nº 13.709/2018)

Para garantir total conformidade com a LGPD, os dados brutos com identificadores pessoais (PII) foram descartados na ingestão. A base final retém apenas atributos estatísticos essenciais (ID, Sexo, Tempo_Liquido). Além disso, o repositório público não inclui o banco bruto real; em seu lugar, disponibiliza-se um script gerador de dados sintéticos (src/00_gerar_dados_sinteticos.py) para fins de testes e reprodutibilidade por terceiros.

2.3 Pipeline de Tratamento em Python

• **Leitura com UTF-8-SIG:** Eliminação de caracteres invisíveis BOM (\ufeff) vindos da exportação.
• **Normalização Decimal:** Substituição de vírgula por ponto (.str.replace(',', '.')) para compatibilidade float.
• **Parsing Temporal:** Uso de pd.to_timedelta().dt.total_seconds() / 60.0 para transformar HH:MM:SS em minutos decimais contínuos.

2.3.1 Estratégia de Parsing e Apresentação Temporal

O dado bruto é ingerido no formato textual HH:MM:SS (ex: 00:18:34). Para viabilizar os cálculos estatísticos (médias, desvios e aplicação da Regra de Sturges) e garantir a precisão dos eixos nos gráficos (Matplotlib/Seaborn), os tempos foram convertidos para **minutos decimais contínuos** (float64, ex: 18.57

min). O formato original HH:MM:SS ou MM:SS fica reservado como camada de apresentação visual para interfaces amigáveis ao usuário leigo.

2.3.2 Conversão de decimais contínuos para textual (HH:MM:SS)

Dado um tempo decimal T_{dec}:

1. **Minutos (MM):** Pega apenas na **parte inteira** do número (descarte a vírgula/casas decimais).

$$MM = \text{Parte Inteira}(T_{\text{dec}})$$

2. **Segundos (SS):** Subtrai a parte inteira ao número decimal (ficando apenas com as casas decimais) e **multiplica por 60**.

$$SS = (T_{\text{dec}} - MM) \times 60$$

Exemplo Prático na Calculadora: Vamos converter $42{,}02$ **minutos** (a mediana feminina do projeto):

1. **Minutos (MM):**
   - A parte inteira de $42{,}02$ é 42.
   - Já temos **42 minutos**.
2. **Segundos (SS):**
   - Pega na parte decimal: $42{,}02 - 42 = 0{,}02$.
   - Na calculadora, digita: 0.02 * 60
   - Resultado: $1{,}2$ **segundos** (arredondado para 01 **segundo**).
- **Resultado:** 42:01 (42 minutos e 1 segundo).

2.3.2 Conversão de textual para decimais contínuos

Dado um tempo textual, utilizaremos:

$$\text{Tempo Decimal} = MM + \left(\frac{SS}{60}\right)$$

Exemplo na Calculadora (38 min e 10 seg):

1. Na calculadora, digita: 10 / 60 = 0.1666...
2. Soma os minutos: 38 + 0.1666... = 38.17 min

3. Arquitetura de Pastas e Stack Tecnológico

A estrutura do projeto foi desenhada de forma modular e clara, separando rigorosamente a ingestão de dados, o pipeline de tratamento programático, os scripts de análise/gráficos e a camada de entregáveis finais:

- dados/raw/: Camada de ingestão bruta intocável (00_dados_corrida.txt). Omitida do repositório remoto via .gitignore para conformidade com a LGPD.
- dados/processed/: Camada de dados higienizados (.csv enxutos de frequências e estatísticas por gênero) e gráficos estáticos de alta resolução exportados em 300 DPI (.png).

- src/: Pipeline de scripts Python modularizados e sequenciados numericamente de 01 a 07, cobrindo desde o saneamento do dado até a renderização dos gráficos por gênero.
- docs/ e provas/: Registros de diário de bordo (diario_de_bordo.txt) e materiais/referências de apoio (provas.txt).
- venv/: Ambiente virtual local isolado, ignorado no versionamento via .gitignore.
- Entregáveis na Raiz: README.md, requirements.txt, além dos relatórios e documentações em PDF e .docx.

Stack Tecnológico e Dependências

- Python: 3.12+
- Pandas: 3.1.0 (Manipulação, limpeza, parsing temporal e agregações de DataFrames)
- NumPy: 2.5.4 (Operações vetoriais, cálculos de frequências e aplicação da Regra de Sturges)
- Matplotlib: 3.11.2 (Motor gráfico base para geração e exportação de figuras em 300 DPI)
- Seaborn: 0.13.2 (Camada visual avançada para estatística: KDE, Histogramas e Boxplots)

4. Diário de Bordo: Erros Encontrados e Soluções

Bug #1: Erro DTypePromotionError / Fail no pd.cut

Causa: Presença de vírgulas e formato string impedindo o cálculo numérico dos bins pelo NumPy.
Solução: Tratamento prévio com .astype(str).str.replace(',', '.') e conversão explícita com pd.to_numeric().

Bug #2: OverflowError / ValueError (Tempo em formato HH:MM:SS)

Causa: O pd.to_numeric transformou strings como '00:18:34' em NaN, zerando os registros válidos (N=0) e gerando log10(0) = -inf no cálculo de Sturges.
Solução: Substituição pelo parser temporal pd.to_timedelta(df['Tempo_Liquido']).dt.total_seconds() / 60.0.

5. Justificativa das Visualizações Gráficas

5.1. Histograma com Curva de Densidade (KDE) (População Geral)

- Função Estatística: Cruzar a distribuição de frequências absolutas (agrupada pelas 11 classes da Regra de Sturges) com uma estimativa suave de densidade kernel (KDE).
- O que revela sobre a pesquisa: Este gráfico permite inspecionar a forma global da distribuição da amostra ($\boldsymbol{N = 1.219}$). Ele evidencia visualmente a assimetria positiva (cauda à direita) da prova: a grande maioria dos atletas concentra-se no pelotão intermediário-rápido, enquanto uma cauda longa de corredores de ritmo mais conservador se estende em direção aos tempos mais altos. Responde à pergunta: "Como se comporta o ritmo macro de toda a massa de concluintes?"

5.2. Ogiva de Galton (Polígono de Frequência Acumulada)

- Função Estatística: Mapear a progressão acumulada dos dados (F_i), acumulando as frequências de cada classe sucessiva em formato de curva ogival (sigmoide).
- O que revela sobre a pesquisa: É a ferramenta visual ideal para análises de corte e percentis. Em vez de olhar para classes isoladas, ela responde instantaneamente a perguntas executivas do tipo: "Quantos atletas (ou qual percentual do total) cruzaram a linha de chegada até os 40 minutos?" ou "Qual o tempo limite que separa os 50% mais rápidos da metade restante?".

5.3. Boxplot Comparativo por Gênero

- Função Estatística: Exibir de forma compacta e lado a lado a posição central (mediana), a dispersão interquartil (IQR — o corpo da caixa) e a identificação estatística de valores atípicos (outliers, representados por pontos isolados nas caudas).
- O que revela sobre a pesquisa: Facilita o teste visual de hipóteses sobre o desempenho relativo entre os grupos. Mostra claramente a diferença de patamar entre as medianas (aproximadamente 34 minutos para o grupo Masculino contra 42 minutos para o Feminino). Além disso, destaca um comportamento analítico importante: a presença de uma densidade maior de outliers superiores distantes na categoria masculina, que puxam a média para cima de forma mais acentuada.

5.4. Curvas de Densidade Sobrepostas (KDE Comparativo)

- Demonstra a topografia contínua da performance por gênero. O pico modal masculino situa-se em torno de 30-32 minutos, enquanto o feminino concentra-se na faixa de 38-42 minutos. Apesar da diferença nos picos, há uma ampla área de interseção entre 34 e 48 minutos, demonstrando um miolo de prova de ritmo compartilhado.

5.4. Curvas de Densidade Sobrepostas (KDE Comparativo: Masculino vs. Feminino)

- Função Estatística: Sobrepor as funções de densidade de probabilidade de dois subgrupos distintos no mesmo plano cartesiano, utilizando transparências (alpha) para evidenciar áreas de sobreposição e desfasamento.
- O que revela sobre a pesquisa: Vai além do Boxplot ao expor a topografia exata das distribuições. Permite observar o deslocamento dos picos modais (o pico de maior concentração masculina situando-se na faixa de 30-32 minutos, frente ao pico feminino concentrado entre 38-42 minutos). O gráfico também revela visualmente a zona de interseção (o miolo da prova onde atletas de ambos os sexos correm no mesmo ritmo), demonstrando que, embora os picos sejam distintos, há uma faixa ampla de performance compartilhada.

6. Insights de Negócio e Recomendações Organizacionais

- **Logística de Hidratação:** Concentrar 75%+ do abastecimento de água na linha de chegada entre 30 e 50 minutos de prova, janela onde se concentra o grosso do fluxo de concluintes.
- **Paridade Estrutural:** A amostra revelou alta paridade de participação (48,4% Feminino vs 51,6% Masculino), exigindo infraestrutura equivalente em áreas de apoio, vestiários e paridade nas premiações por categoria.
- **Gestão de Funil de Chegada:** Dimensionar os pórticos e corredores de dispersão pós-prova para absorver o pico de 284 atletas concentrados na faixa modal (37,5 a 43,8 min), evitando congestionamentos críticos.
- **Perspectiva Comportamental e Superação (O Verdadeiro Desafio):** A análise da cauda da distribuição e da dispersão ampla dos tempos demonstra que a grande massa de participantes é composta por corredores focados na superação pessoal e na consistência, e não na disputa de pódio de elite. O dado mostra que há um volume expressivo de concluintes em faixas de tempo mais altas que encontram na prova um marco de vitória individual. O insight principal para novos corredores é claro: comece a correr sem focar naqueles que estão na frente ou em recordes inatingíveis para o momento inicial; os dados provam que o pelotão é plural, acolhedor e que o único adversário real é o seu próprio limite de ontem.

7. Anexo: Script de Geração de Dados Sintéticos (LGPD)

```
import pandas as pd
import numpy as np

def gerar_base_sintetica(n_registros=1200,
arquivo_saida='dados/processed/dados_sinteticos_5km.csv'):
    np.random.seed(42)
    sexos = np.random.choice(['M', 'F'], size=n_registros, p=[0.52, 0.48])
    tempos = []
    for s in sexos:
        if s == 'M':
            t = np.random.gamma(shape=12, scale=3) # Média ~36 min
        else:
```

```
            t = np.random.gamma(shape=14, scale=3.1) # Média ~43 min
        tempos.append(max(18.0, round(t, 2)))

    df = pd.DataFrame({
        'ID': range(1, n_registros + 1),
        'Sexo': sexos,
        'Tempo_Liquido_Min': tempos
    })
    df.to_csv(arquivo_saida, index=False)
    print(f'Base sintética gerada com sucesso: {arquivo_saida}')

if __name__ == '__main__':
    gerar_base_sintetica()
```